

# **Algorithms for Big Data Analysis : Homework #5**

Due on April 11, 2017 at 23:59pm

*Wen Zaiwen*

**Hu Tao**

## Problem 1

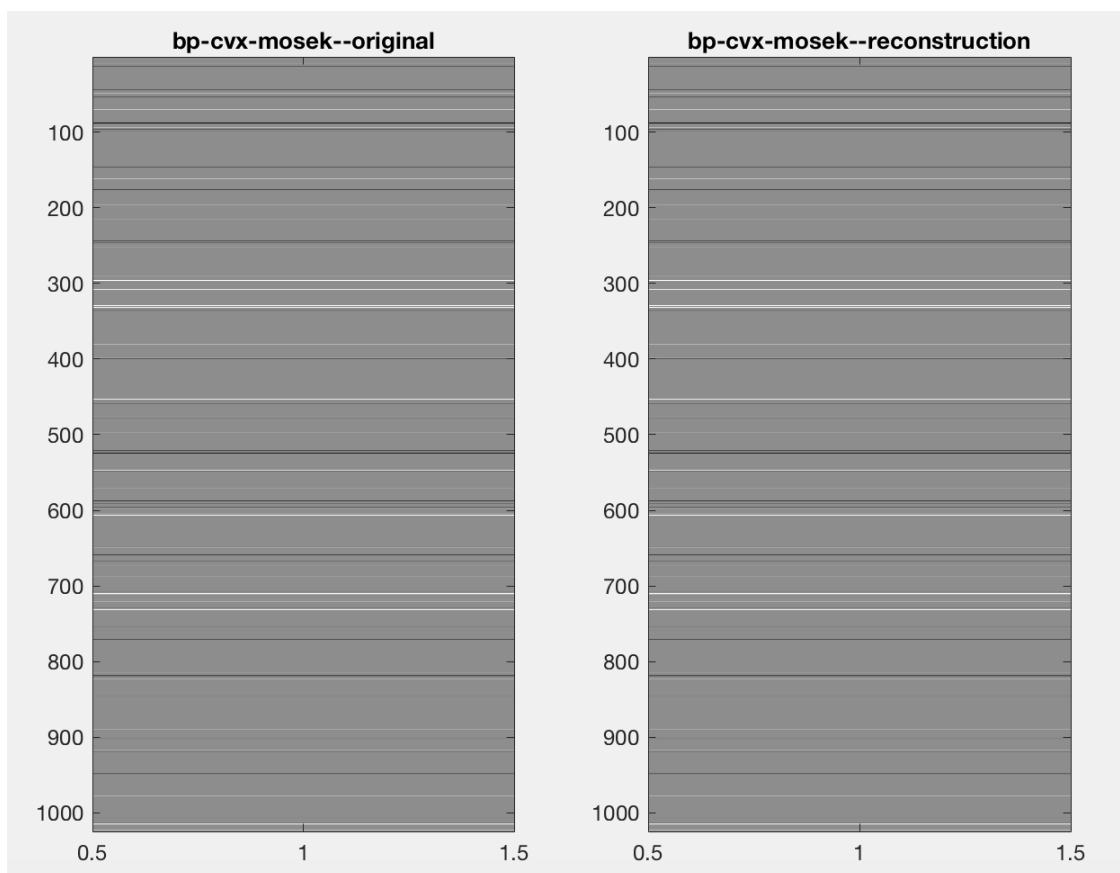
### Solution

Basic Pursuit	Accuracy		Run Time(s)	
	A=512*1024	A=1024*2048	A=512*1024	A=1024*2048
CVX_Mosek	6.080e-10	1.469e-09	2.74	16.86
Mosek	5.075e-10	2.705e-08	2.40	15.26
Augmented Lagragian	7.954e-10 —	9.370e-07 —	3.19 —	6.04 —
Dual ADMM	8.111e-11 —	3.603e-11 —	1.83 —	14.21 —

总结:

- 1) 在Augmented Lagragian方法中,  $\tau$ 如果使用BB步长, 结果会不收敛, 但是Dual ADMM方法就没有这个问题 (目前暂时不知道此bug的原因)。因此在Augmented Lagragian中使用的是固定步长, 我设置 $\tau = 0.001$ , 这样设置很显然很不好, 比如我将问题的规模扩大一倍,  $A=1024*2048$ ,  $\tau = 0.001$ 就不起作用了, 需要将 $\tau = 0.0001$ , 总之 $\tau$ 是一个很敏感的参数, 最好使用BB步长动态调整。
- 2) mosek的准确率没有CVX Mosek的准确率高, 很有可能是我fomulate的形式没有cvx帮我fomulate的形式更容易解。
- 3) Dual ADMM的准确率和运行时间还是比较满意的。

(a).我使用的是cvx中的mosek来求解.结果如下:



代码bp\_cvx\_mosek.m如下:

```
function [x0, out] = bp_cvx_mosek(A, b, opts)
n = size(A,2);
cvx_solver mosek
cvx_begin
variable x(n);
minimize(norm(x,1));
subject to
A * x == b;
cvx_end

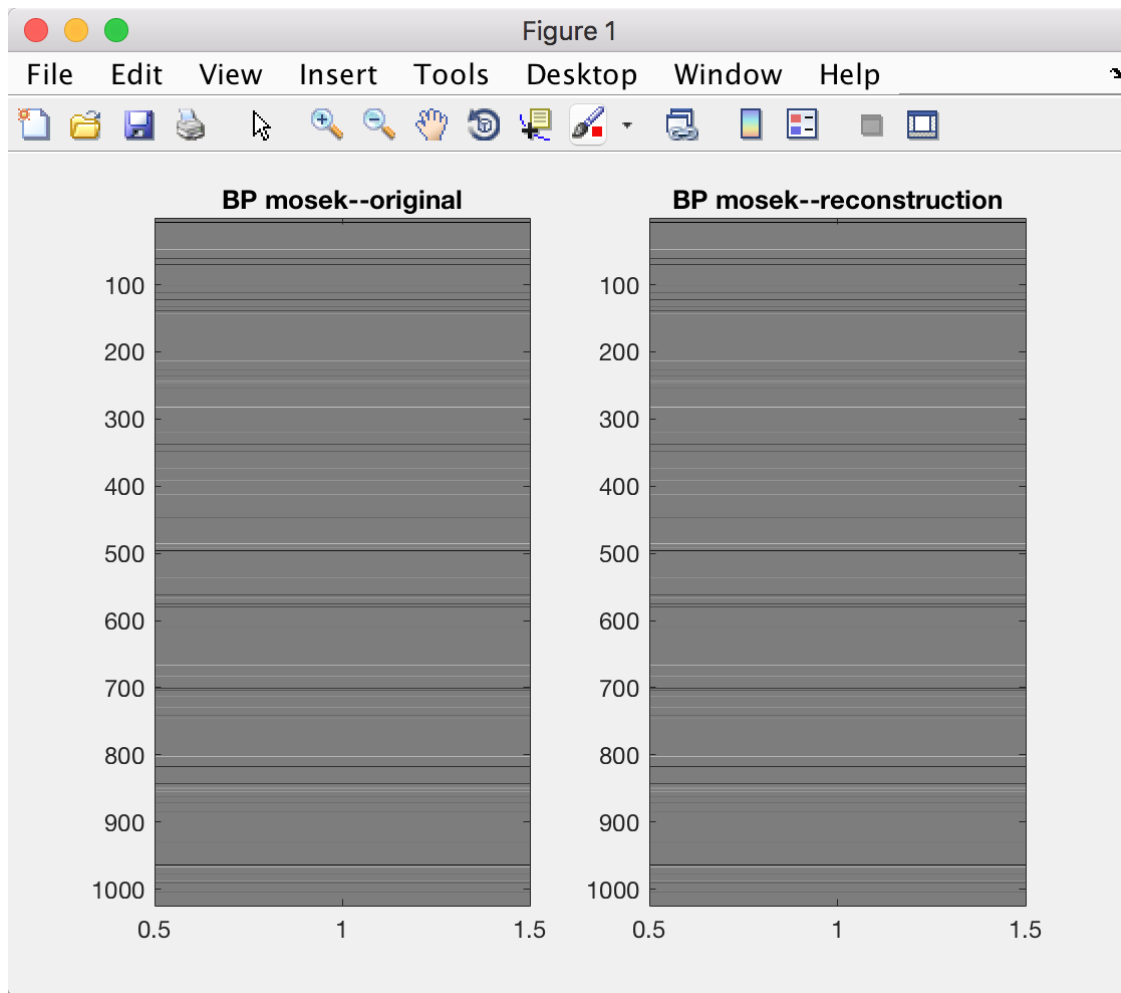
x0 = x;
out.x = x;
end
```

(b).

对照<http://docs.mosek.com/8.0/toolbox/linprog.html>中描述的格式进行转换, 我们将basis pursuit问题按照mosek的格式进行了转换:

$f$ 为 $2n \times 1$ 矩阵,  $A$ 为 $\begin{pmatrix} -E & -E \\ -E & E \end{pmatrix}$ ,  $b$ 为 $2n \times 1$ 矩阵,  $B$ 为形式为 $\begin{pmatrix} 0 & 0 \\ 0 & A \end{pmatrix}$ 的矩阵,  $c$ 为 $2m \times 1$ 的矩阵.

结果如下:



具体如下代码bp\_mosek.m所示:

```
function [x0, out] = bp_mosek(A, b, opts)
m = size(A,1);
n = size(A,2);
x0 = rand(n,1);
mosek_f = [ones(n,1);zeros(n,1)];

mosek_A = [-eye(n),-eye(n);-eye(n),eye(n)];

mosek_b = zeros(2*n,1);

mosek_B = [zeros(m,n),zeros(m,n);zeros(m,n),A];

mosek_c = [zeros(m,1);b];

mosek_l = -ones(2*n,1)*inf;
mosek_u = ones(2*n,1)*inf;
options.Write = 'test.opf';
[x,fval,exitflag,output,lambda] =
    linprog(mosek_f,mosek_A,mosek_b,mosek_B,mosek_c,mosek_l,mosek_u,x0,options);
```

```

x0 = x(n+1:2*n);
out.x = x(n+1:2*n);

end

```

(c).针对增广拉格朗日函数，我们使用PGD([1])方法进行优化。  
公式推到如下：

$$\begin{aligned}
& \|x\|_1 + \lambda^T(Ax - b) + \frac{1}{2\mu}\|Ax - b\|_2^2 \\
& = \|x\|_1 + \frac{1}{2\mu}\|Ax - b + \mu\lambda\|_2^2
\end{aligned}$$

对右半部分求导 可以得到  $g = A^T(Ax - b + \mu\lambda)$ , 对上面的式子进行线性化，可以得到，

$$\begin{aligned}
x_{k+1} & = \|x\|_1 + \frac{1}{\mu}((g_k)^T(x - x_k) + \frac{1}{2\tau}\|x - x_k\|_2^2) \\
& = \|x\|_1 + \frac{1}{2\tau\mu}\|x - x_k + \tau g_k\|_2^2
\end{aligned}$$

推导到这里就可以shrinkage来求解了。最终的迭代公式如下：

---

**Algorithm 1** Basic Pursuit Augmented Lagrangian Algorithm

---

**Require:** initial value  $x_0, \lambda_0, \mu, \text{final } \mu_{final}$

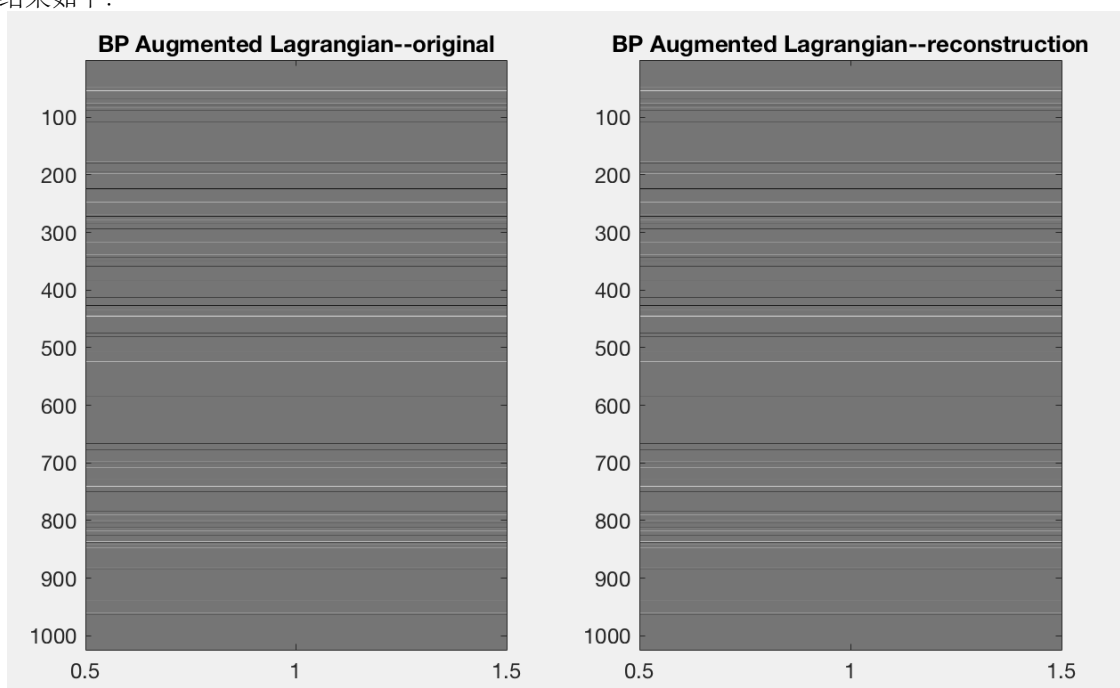
```

while  $\mu > \mu_{final}$  do
   $\mu = \frac{\mu}{10}$ 
  while not satisfy the stop condition do
    calculate BB step:  $\tau$ 
     $x - \text{update} : x_{k+1} = \text{shrink}(x_k - \tau g_k, \mu\tau)$ 
     $\lambda - \text{update} : \lambda_{k+1} = \lambda_k + \frac{0.618}{\mu}(Ax_k - b)$ 
  end while
end while
Output x

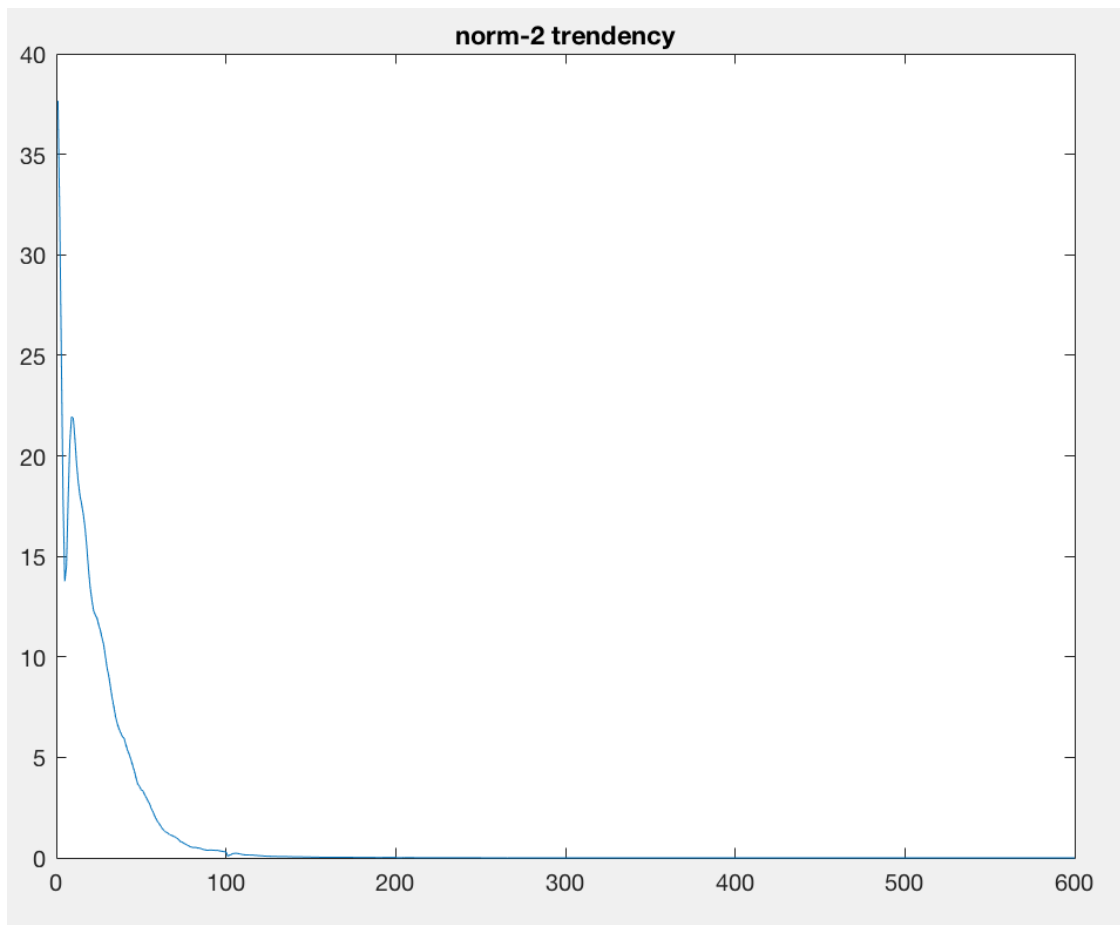
```

---

代码使用了BB步长进行优化，在计算 $\lambda_k$ 的时候，使用了0.618的黄金神奇步长。  
具体结果如下：



变量x的当前与前一次的差的3范数变化如下:



具体代码见bp\_al.m。

(d).

求出对偶以后，最终的ADMM([2])迭代过程如下:

---

**Algorithm 2** Basic Pursuit Dual ADMM Algorithm

---

**Require:** initial value  $S_0, \lambda_0, x_0, \mu, \mu_{final}$

**while**  $\mu > \mu_{final}$  **do**

$$\mu = \frac{\mu}{10}$$

**while** not satisfy the stop condition **do**

$$\lambda^{k+1} = (AA^T)^{-1}(\mu(-Ax^k + b) + As^k)$$

$$S^{k+1} = P_{[-1,1]}(A^T \lambda^{k+1} + \mu x^k)$$

$$x^{k+1} = x^k + \frac{0.618}{\mu}(A^T \lambda^{k+1} - S^{k+1})$$

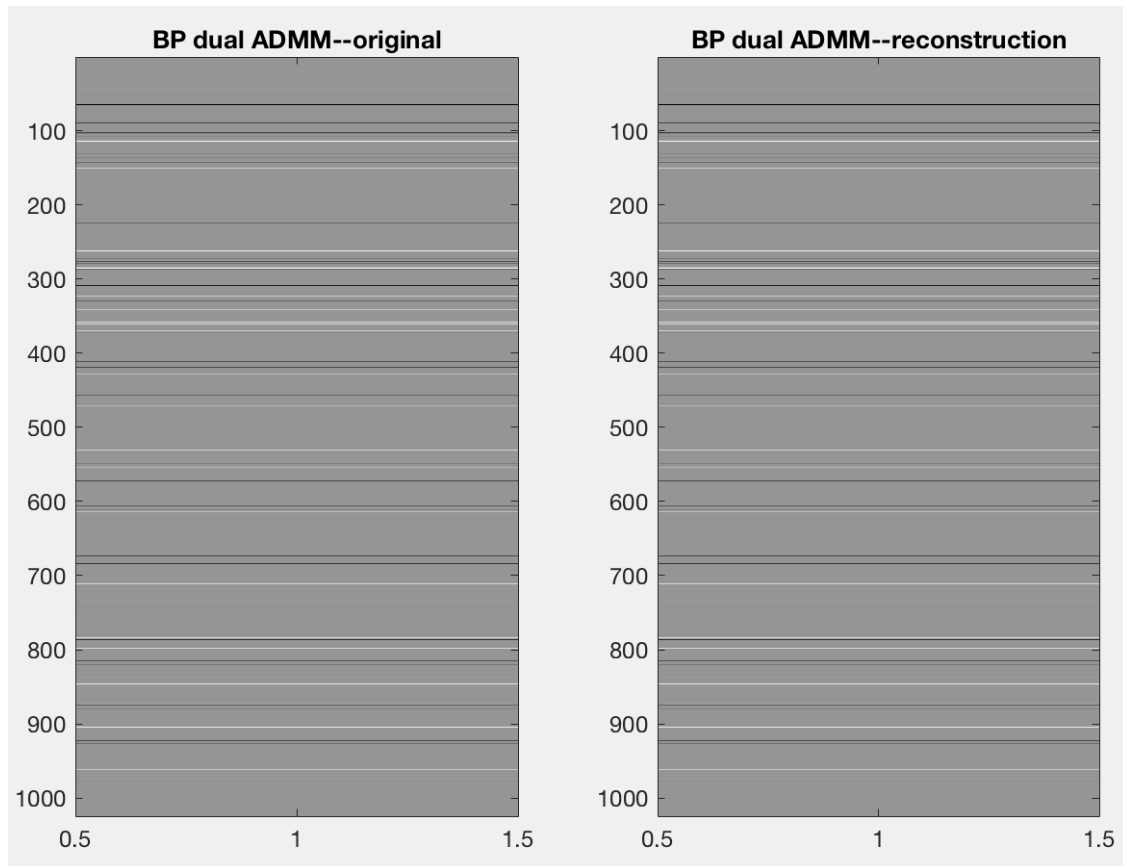
**end while**

**end while**

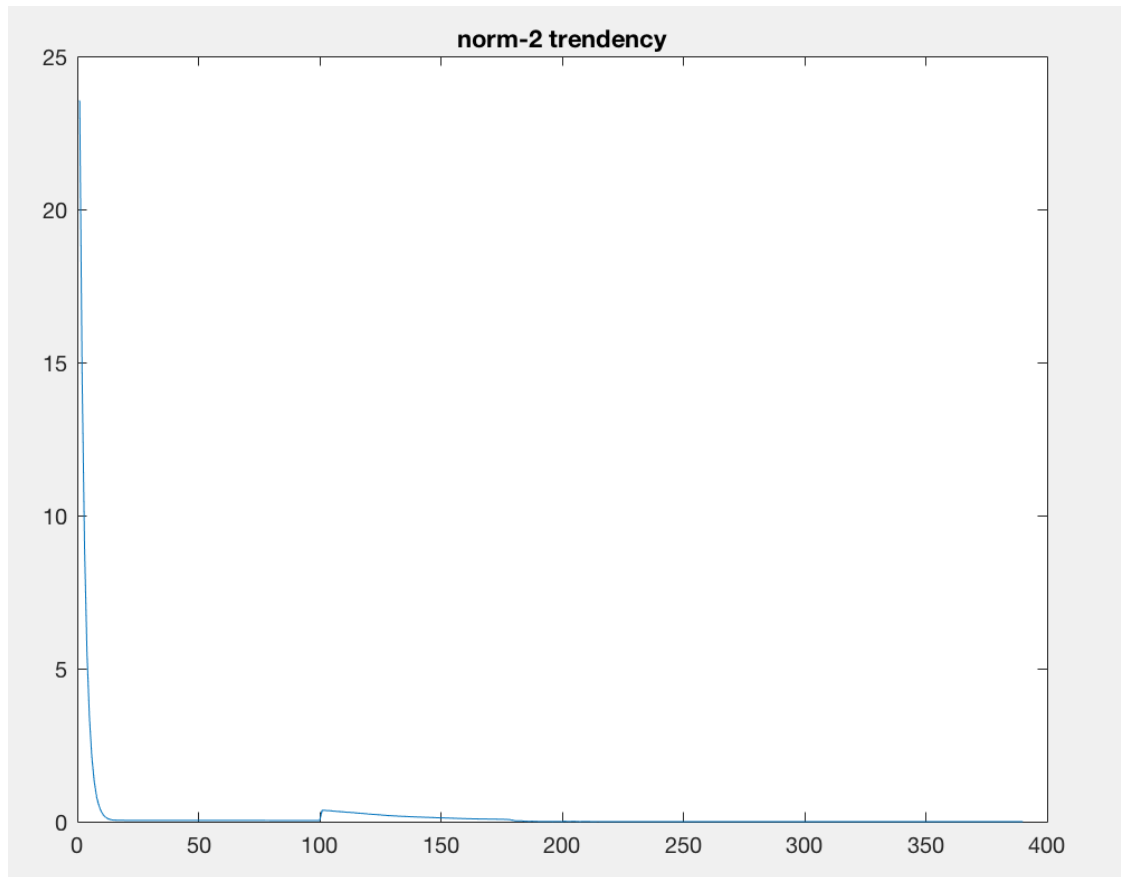
Output  $x$

---

最终得到的结果如下所示:



变量x的当前与前一次的差的3范数变化如下:



最终的代码见bp\_dual\_admm.m.

## Problem 2

### Solution

(a).论文([3])使用了两种方式来生成样本，如下：

model 1:

---

```
function [s] = generate_s()
%model 1
s = ones(30,30);
for i=1:30
for j=1:30
s(i,j) = power(0.6,abs(i-j));
end
end
end
```

---

model 2:

---

```
function [s] = generate_s_2()
%model 1
s = zeros(30,30);
```

---



```

sample = [0,0.5];
for i=1:30
for j=1:30
tt = discreteRnd([0.9,0.1],1);
s(i,j) = sample(tt);
end
end

for i=1:30
s(i,i) = 0;
end

for i=1:100
n_m = s+eye(30)*i/10.0;
ttt = cond(n_m);
if ttt >50 & ttt<100
fprintf('condition number: %s\n',ttt);
s =n_m;
break
end
end

end

function x = discreteRnd(p, n)
% Generate samples from a discrete distribution (multinomial).
% Input:
%   p: k dimensional probability vector
%   n: number of samples
% Output:
%   x: k x n generated samples x~Mul(p)
% Written by Mo Chen (sth4nth@gmail.com).
if nargin == 1
n = 1;
end
r = rand(1,n);
p = cumsum(p(:));
[~,x] = histc(r,[0;p/p(end)]);
end

```

(b). 对偶推导如下:

令  $Z=X$ , 原问题可以转换成:

$$\begin{aligned} \min_{X,Z} \quad & \text{tr}(SX) + \rho \|Z\|_1 - \log \det X \\ \text{s.t.} \quad & Z = X, X \succ 0 \end{aligned}$$

上述问题的Lagrangian函数为:

$$L(X, Z, A, B) = \text{tr}(SX) + \rho \|Z\|_1 - \log \det X + \langle A, Z - X \rangle - \langle B, X \rangle + AZ + \rho \|Z\|_1$$

对于变量Z,若要 $AZ + \rho\|Z\|_1$ 最小, 则必须要有 $\|A\|_\infty \leq \rho$ ,否则就会出现unbounded.  
对于变量X,对X求导可以得到:

$$X = (S^T - A - B)^{-1}$$

综合上述分析, 原问题的对偶函数为:

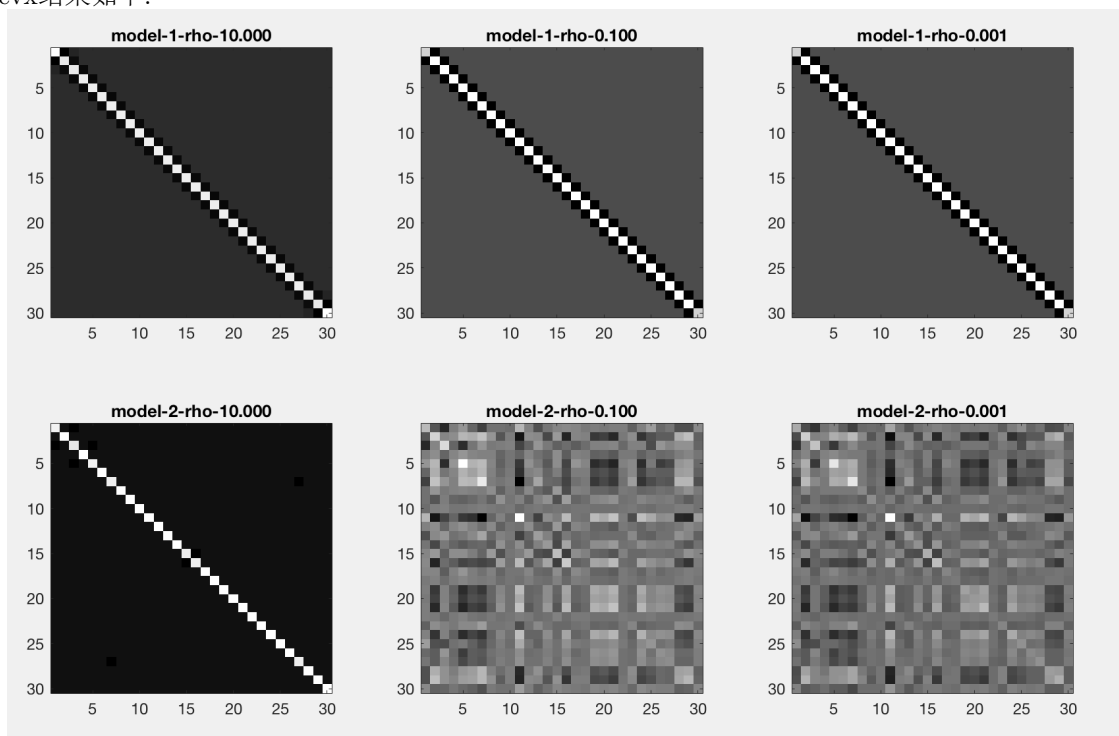
$$\begin{aligned} g(A, B) &= \inf_{X, Z} L(X, Z, A, B) = L(X, Z, A, B)_{X=(S^T-A-B)^{-1}} \\ &= \langle S^T - A - B, (S^T - A - B)^{-1} \rangle - \log \det(S^T - A - B)^{-1} \\ &\quad \text{s.t. } \|A\|_\infty \leq \rho, B \succeq 0 \end{aligned}$$

因此原问题的对偶问题为:

$$\begin{aligned} \max_{A, B} \quad & \langle S^T - A - B, (S^T - A - B)^{-1} \rangle - \log \det(S^T - A - B)^{-1} \\ \text{s.t.} \quad & \|A\|_\infty \leq \rho, B \succeq 0 \end{aligned}$$

(c).

使用cvx结果如下:



其中, 当 $\rho=0.1$ 或者 $0.001$ , model=2时会出现unbounded现象。  
代码如下:

---

```
function [out] = sice_cvx_mosek(S,rho)
n = size(S,2);
cvx_solver mosek
cvx_begin
variable X(n,n);
minimize( - log_det(X) + trace(S*X) + rho*norm(X,1));
subject to
X == semidefinite(n);
```

---

```
cvx_end
```

```
out = X;
end
```

---

(d)

本问题和boyd网站上的题目类似，为了方便自己和boyd实现的结果对比，接下来采用boyd的变量命名。  
原问题为：

$$\begin{aligned} \max_X \quad & \log \det X - \text{tr}(SX) - \gamma \|Z\|_1 \\ \text{s.t.} \quad & Z = X, X \succeq 0 \end{aligned}$$

原问题转换为标准的lagrangian问题：

$$\begin{aligned} \min_X \quad & -\log \det X + \text{tr}(SX) + \gamma \|Z\|_1 \\ \text{s.t.} \quad & Z = X, X \succeq 0 \end{aligned}$$

相应的增广Lagrangian函数为：

$$\begin{aligned} AL(X, Z, \gamma, W) &= \text{tr}(SX) - \log \det X + \gamma \|Z\|_1 + \langle W, -Z + X \rangle + \frac{1}{2\rho} \|X - Z\|_F^2 \\ &= \text{tr}(SX) - \log \det X + \gamma \|Z\|_1 + \frac{1}{2\rho} \|X - Z + \rho W\|_F^2 \end{aligned}$$

使用ADMM来求解该问题：

$$\begin{aligned} X &= \arg \min_X (\text{tr}(SX) - \log \det X + \frac{1}{2\rho} \|X - Z + \rho W\|_F^2) \\ Z &= \text{shrinkage}(x + \rho W, \rho\gamma) \\ W &= W + \frac{1}{\rho}(X - Z) \end{aligned}$$

主要是第一步中的X-update比较麻烦，对右边求导，并且右乘矩阵X，化简以后可以得到：

$$X^2 + (\rho W + \rho S - Z)X - \rho E = 0$$

首先考虑对 $\rho W + \rho S - Z$ 做谱分解，得到：

$$\begin{aligned} \rho W + \rho S - Z &= Q \Lambda Q^T \\ \tilde{\Lambda}_{ii} &= \frac{-\Lambda_{ii} + \sqrt{\Lambda_{ii}^2 + 4\rho}}{2} \\ X_{new} &= Q \tilde{X} Q^T \end{aligned}$$

这样就解决了x-update的问题，最终的算法流程如下：  
具体代码参考covsel.m.

**Algorithm 3** Sparse Inverse Covariance Estimation Algorithm**Require:** initial value  $X_0, \gamma, \rho, W_0, Z_0, \text{final } \rho_{final}$ 


---

```

while  $\rho > \rho_{final}$  do
   $\rho = \frac{\rho}{10}$ 
  while not satisfy the stop condition do
    spectraldecomposition :  $\rho W + \rho S - Z = Q \wedge Q^T$ 
     $\tilde{\Lambda}_{ii} = \frac{-\wedge_{ii} + \sqrt{\wedge_{ii}^2 + 4\rho}}{2}$ 
    X-update :  $X_{new} = Q \tilde{X} Q^T$ 
    Z-update :  $Z_{new} = \text{shrinkage}(x + \rho W, \rho \gamma)$ 
     $W_{new} = W + \frac{1}{\rho}(X - Z)$ 
  end while
end while
Output x

```

---

**Problem 3****Solution**

(a). 做变量替换以后如下:

$$\begin{aligned} \min_{X,Y} \quad & \|SX - I\|_F^2 \leq \sigma^2 \\ \text{s.t.} \quad & Y = X, X \succeq 0 \end{aligned}$$

对应的Lagrangian函数如下:

$$\begin{aligned} L(X, Y, t, A, B) &= \|Y\|_1 + t(\|SX - I\|_F^2 - \sigma^2) + \langle A, Y - X \rangle - \langle B, X \rangle \\ \frac{\partial L}{\partial X} &= -2tS^T(SX - I) - A - B = 0 \\ X &= (S^T S)^+ [S^T - \frac{1}{2t}(A + B)] \end{aligned}$$

下面再以Y为研究对象:

$$\min_Y L(X, Y, t, A, B) = \|Y\|_1 + \langle A, Y \rangle$$

当 $\|A\|_\infty \leq 1$ 时, 最小值为0, 否则unbounded.

因此原问题的对偶函数为:

$$g(t, A, B) = t(\|SX - I\|_F^2 - \sigma^2) - (A + B, X)$$

其中 $X = (S^T S)^+ [S^T - \frac{1}{2t}(A + B)]$ 


最后原问题的对偶问题为:

$$\begin{aligned} \max_{t,A,B} \quad & t(\|SX - I\|_F^2 - \sigma^2) - (A + B, X) \\ \text{s.t.} \quad & \|A\|_\infty \leq 1, B \succeq 0, t > 0 \end{aligned}$$

其中 $X = (S^T S)^+ [S^T - \frac{1}{2t}(A + B)]$ 

(b).

使用cvx结果如下:



当 $\rho=0.1$ 或者 $0.001$ , $\text{model}=2$ 的时候, 会出现infeasible的现象。  
代码如下:

---

```
function [out] = f_cvx_mosek(S,rho)
n = size(S,2);
I = eye(n);
cvx_solver mosek
cvx_begin
variable X(n,n);
minimize(norm(X,1));
subject to
X == semidefinite(n);
norm(S*X-I,'fro') <= rho;
cvx_end

out = X;
end
```

---

(c)  
使用SDPT3代码如下:

---

```
content...
```

---

(d).

//TODO

## References

- [1] W. Yin, S. Osher, D. Goldfarb, and J. Darbon, “Bregman iterative algorithms for  $\ell_1$ -minimization with applications to compressed sensing,” *SIAM Journal on Imaging sciences*, vol. 1, no. 1, pp. 143–168, 2008.
- [2] J. Yang and Y. Zhang, “Alternating direction algorithms for  $\ell_1$ -problems in compressive sensing,” *SIAM journal on scientific computing*, vol. 33, no. 1, pp. 250–278, 2011.
- [3] T. Cai, W. Liu, and X. Luo, “A constrained  $\ell_1$  minimization approach to sparse precision matrix estimation,” *Journal of the American Statistical Association*, vol. 106, no. 494, pp. 594–607, 2011.